

VLA机器人数据清洗与质量评估指标文档

1. 文档目的

本文档用于定义 VLA（Vision-Language-Action）机器人数据在采集、转换、清洗、标注和训练前的质量检查标准。

适用的数据流程为：

```
机器人采集
↓
ROS2 / MCAP 原始数据
↓
数据检查与清洗
↓
时间同步与格式转换
↓
LeRobot 数据集
↓
任务 / 子任务标注
↓
训练前质量验证
↓
VLA模型训练（如  $\pi 0.5$ ）
```

数据清洗的核心目标不是简单删除“异常数据”，而是确保最终进入训练的数据满足以下要求：

- 数据完整
- 时间同步可靠
- 图像质量可用
- 机器人状态连续
- 动作数据正确
- Episode 完整有效
- 语言标注与任务一致
- 数据分布合理
- 满足模型训练格式和归一化要求

2. 数据质量总体框架

VLA 数据质量主要分为以下 8 类：

类别	主要内容	优先级
数据完整性	Topic、帧、字段、维度是否完整	P0
时间质量	FPS、时间戳、Jitter、丢帧	P0

类别	主要内容	优先级
多模态同步	Camera、State、Action 是否对齐	P0
图像质量	黑屏、模糊、冻结、曝光	P1
State质量	NaN、越界、跳变、异常速度	P0
Action质量	动作跳变、延迟、饱和、连续性	P0
Episode质量	成功、失败、空闲、完整性	P0
标注与数据分布	Task/Subtask、类别平衡、统计分布	P1/P2

其中：

- **P0**：必须检查，不通过原则上不得进入训练集
- **P1**：强烈建议检查，可根据实际数据设 **Warning** 阈值
- **P2**：数据规模扩大后逐步引入

3. 原始数据完整性指标

3.1 Topic 完整性

检查每个 Episode 是否包含预期数据流。

典型数据包括：

Camera

├─ Head Camera

├─ Left Wrist Camera

└─ Right Wrist Camera

Robot State

├─ Joint State

├─ TCP Pose

└─ Gripper State

Action

├─ Joint Command

├─ TCP Command

└─ Gripper Command

检查指标

- 必要 Topic 是否存在
- Topic 消息数量是否正常
- Topic 是否中途停止
- 不同 Episode 的 Topic Schema 是否一致

建议判定

必要 Topic 缺失：
FAIL

非关键辅助 Topic 缺失：
WARNING

3.2 数据 Schema 一致性

检查：

- State 维度
- Action 维度
- Joint 数量
- 图像分辨率
- 数据类型
- Camera 数量

例如：

Episode 1: state dim = 16
Episode 2: state dim = 16
Episode 3: state dim = 14

Episode 3 应被标记为异常。

4. 时间质量指标

时间质量是机器人/VLA数据最重要的质量维度之一。

不同传感器允许采用不同采样频率，例如：

Camera	30 Hz
Robot State	50 Hz
Action	25~30 Hz

不同频率本身不是问题，关键是时间戳必须可靠，并能够在后处理阶段准确对齐。

4.1 实际采样频率

实际频率计算：

```
Actual FPS =  
(消息数量 - 1) / (最后时间戳 - 第一时间戳)
```

需要分别统计：

- Camera FPS
- Joint State FPS
- TCP FPS
- Action FPS
- Gripper FPS

示例：

```
Head Camera  
Expected: 30 Hz  
Actual:    29.97 Hz
```

4.2 帧间隔

计算连续消息时间间隔：

```
 $\Delta t = \text{timestamp}[i] - \text{timestamp}[i-1]$ 
```

统计：

- Mean
- Standard Deviation
- Min
- Max
- P95
- P99

对于 30 Hz 相机：

```
理论帧间隔  $\approx$  33.3 ms
```

如果出现：

```
33 ms  
33 ms  
34 ms
```

```
120 ms
33 ms
```

则可能存在丢帧或系统阻塞。

4.3 Jitter

Jitter 用于反映采样周期的不稳定程度。

```
Jitter =
| 实际帧间隔 - 理论帧间隔 |
```

建议统计：

- Mean Jitter
- P95 Jitter
- P99 Jitter
- Max Jitter

工程初始参考：

Camera 30Hz	建议判定
P95 < 5 ms	GOOD
5~15 ms	WARNING
>15 ms	CHECK
单次 Gap >100 ms	WARNING / FAIL

以上阈值建议根据设备实际运行情况进一步校准。

4.4 时间戳连续性

必须检查：

- Timestamp 是否单调递增
- 是否存在重复 Timestamp
- 是否存在 Timestamp 回退
- 是否存在异常大间隔

原则上：

```
Timestamp Regression > 0
→ FAIL
```

5. 多模态同步指标

VLA 数据通常同时包含：

```
Image
Robot State
Action
Language
```

模型训练时需要将这些数据映射到统一时间轴。

5.1 Camera 同步误差

对于：

```
Head Camera
Left Wrist Camera
Right Wrist Camera
```

计算：

```
Camera Sync Error =
|Camera Timestamp - Reference Timestamp|
```

统计：

- Mean
- P95
- P99
- Max

如果三路相机具有硬件同步能力，应优先保证采集时刻同步。

5.2 State 同步误差

例如统一时间点：

```
Dataset Timestamp = 10.000 s
```

```
Camera = 10.002
State  = 9.998
```

则：

```
State Sync Error = 2 ms
```

需要统计整个 Episode 的同步误差分布。


5.3 Action 同步误差

Action 对齐尤其重要。

不能简单假设：

```
Observation(t)
→ Action(t)
```

机器人遥操作通常存在：



因此实际关系可能为：

```
Observation(t)
→ Action(t + Δt)
```

建议分析 Action latency，并在数据转换阶段进行统一补偿。

6. 图像质量指标

6.1 图像解码成功率

检查所有图像是否能够正常解码。

指标：

Decode Success Rate

建议：

关键 Camera 解码失败
→ FAIL / Episode剔除

6.2 黑屏与欠曝

检测：

- 图像平均亮度
- 低亮度像素比例
- 全黑或近似全黑图像

用于发现：

- Camera 未启动
- 镜头遮挡
- 光照异常

6.3 过曝

统计高亮像素比例，例如：

pixel > 250

用于检测：

- 强光
- 自动曝光异常
- 视觉信息丢失

6.4 模糊检测

可通过 Laplacian Variance 等指标检测严重运动模糊或失焦。

目标不是删除所有存在运动模糊的数据，而是识别：

无法有效识别物体或场景

的异常帧。

6.5 Frozen Frame

需要检测：

Timestamp 正常变化
但连续图像内容完全不变化

常见原因：

- Camera pipeline 卡死
- Driver 异常
- 数据重复写入

可使用：

- Frame MSE
- SSIM
- Perceptual Hash

等方法进行检测。

7. Robot State质量指标

7.1 NaN / Inf

检查所有机器人状态：

Joint
TCP
Gripper

是否包含：

NaN
Inf

判定建议：

```
出现 NaN / Inf  
→ FAIL
```

7.2 Joint Range

检查：

```
joint_min <= joint_position <= joint_max
```

超过机器人实际关节限制的数据应被标记。

7.3 Joint Velocity

计算：

```
velocity =  
(q[t] - q[t-1]) / Δt
```

用于检测：

- Encoder异常
 - 数据跳变
 - 时间戳异常
-

7.4 Joint Acceleration

进一步计算：

```
acceleration =  
(v[t] - v[t-1]) / Δt
```

异常大的加速度通常意味着：

- State跳变
 - Tracking异常
 - 数据采集异常
-

8. Action质量指标

VLA最终学习的是：

```
Observation  
→ Action
```

因此 Action 数据质量优先级非常高。

8.1 Action完整性

检查：

- Action维度
 - Action缺失
 - NaN / Inf
 - Action类型一致性
-

8.2 Action范围

检查：

```
Action Min  
Action Max
```

是否处于机器人允许范围。

8.3 Action Jump

连续 Action：

```
Action[t]  
Action[t+1]
```

变化不应出现明显非物理跳变。

可以计算：

```
|Action[t] - Action[t-1]|
```

用于检测：

- 遥操作异常

- 数据损坏
- 单位错误
- 时间错位

8.4 Action Smoothness

可以从速度、加速度、Jerk 等角度分析。

用于发现：

遥操作抖动

错误插值

控制命令异常

8.5 Action Saturation

如果 Action 有固定范围，例如：

$[-1, 1]$

则需要统计：

$|action| > 0.99$

的比例。

若大量 Action 长时间处于极限值，需要检查：

- 控制器是否饱和
- 数据归一化是否错误
- 动作空间是否定义不合理

9. Episode质量指标

Episode 是 VLA 数据管理的基本单位之一。

每条 Episode 建议至少包含：

任务开始

↓

机器人执行

↓
任务成功 / 失败
↓
Episode结束

9.1 Episode Duration

统计：

- Duration
- Frame Count
- 有效操作时间

用于识别：

- Episode过短
- Episode异常长
- 数据录制未正确停止

9.2 Idle Ratio

大量无动作数据会降低训练数据有效密度。

可以计算：

Idle Ratio =
静止帧数量 / 总帧数量

静止可通过以下指标定义：

- Action变化低于阈值
- Joint速度低于阈值

9.3 Motion Ratio

对应：

Active Motion Ratio

用于判断 Episode 是否包含有效操作。

9.4 Task Success

每条 Episode 强烈建议增加：

```
success = true / false
```

失败数据进一步增加：

```
failure_reason
```

例如：

```
grasp_failed  
object_dropped  
collision  
timeout  
teleop_abort  
sensor_failure
```

10. Task语言标注

VLA需要语言与机器人行为建立对应关系。

Episode级至少需要：

```
Task Instruction
```

例如：

```
Pick up the red gear and place it into the tray.
```

建议语言中尽量包含：

```
操作  
+  
目标物体  
+  
目标位置
```

避免过度模糊描述，例如：

Move object.

11. Subtask标注

长任务建议进一步切分为 Subtask。

例如：

0.0s	2.2s	3.4s	5.1s	8.0s
Reach	Grasp	Lift	Move	Place

每个 Subtask 建议包含：

subtask_name
start_frame
end_frame
start_time
end_time

需要检查：

- Subtask 是否重叠
- 是否存在明显 Gap
- Boundary 是否合理
- Subtask 与视频内容是否一致

12. 标注质量指标

对于人工或VLM自动标注，需要检查：

Language ↔ Video
Language ↔ Action
Task ↔ Object
Task ↔ Target Position
Task ↔ Success Result

例如：

Video:

Blue Cube

Label:

Pick up the red cube

应判定为标注错误。

13. VLM自动标注策略

VLM可以用于：

- 自动生成Task描述
- 自动生成Subtask
- 自动寻找Subtask Boundary
- 自动识别场景与物体

推荐流程：

VLM自动标注

↓

结构合法性检查

↓

人工抽检

↓

异常修正

↓

正式进入训练集

VLM自动标注不建议未经检查直接作为最终真值。

14. 数据分布指标

随着数据规模扩大，需要持续检查数据集分布。

建议统计：

Task Distribution

例如：

Pick	45%
Place	30%

Insert	15%
Assembly	10%

避免某些任务占比过高。

Object Distribution

统计：

- 不同物体
- 不同颜色
- 不同尺寸
- 不同类别

Scene Distribution

统计：

- 工作台
- 位置
- 背景
- 光照
- 相机视角

Trajectory Distribution

避免大量重复或高度相似轨迹。

15. 重复数据检测

需要检测：

完全重复Episode
近似重复Episode

可使用：

- Video Hash
- Trajectory Hash
- Initial State / Final State
- Visual Embedding
- Trajectory Embedding

用于降低重复数据占比，提高有效数据多样性。

16. 数据归一化统计

进入 n0.5 等模型训练前，需要统计：

```
Mean
Std
Min
Max
Q01
Q99
```

主要针对：

```
Observation State
Action
```

推荐重点关注：

```
Q01
Q99
```

因为 Min/Max 容易受到极端异常数据影响。

16.1 低方差维度

如果：

```
std ≈ 0
```

说明该维度几乎没有变化。

需要判断：

- 该自由度是否未使用
- 传感器是否失效
- 是否应该参与模型归一化

17. 推荐质量状态

建议每个 Episode 最终输出三级状态：

PASS
WARNING
FAIL

PASS

数据完整且满足训练要求。

WARNING

存在一定异常，但经过确认后仍可使用。

例如：

Camera jitter略高
Idle ratio偏高
少量模糊帧

FAIL

原则上不得直接进入训练。

例如：

Topic缺失
NaN / Inf
Timestamp回退
Camera长时间失效
State/Action维度错误
严重Action异常

18. Quality Score设计

除了状态之外，可以额外提供0~100的数据质量评分。

参考权重：

类型	权重
时间质量	25
图像质量	15
State质量	15
Action质量	20
Episode质量	15
标注质量	10
合计	100

示例：

```
{
  "episode": 137,
  "quality_score": 82.4,
  "status": "WARNING",
  "flags": [
    "camera_jitter_high",
    "idle_ratio_high"
  ]
}
```

质量评分主要用于：

- 数据排序
- 快速筛查
- 数据版本对比

不建议单独依赖 Quality Score 决定是否删除数据，应同时保留具体异常 Flags。

19. 第一阶段推荐执行指标

项目初期不建议一次性实现全部指标。

第一阶段优先实现：

P0：必须完成

Topic完整性
Schema一致性
Timestamp连续性
实际FPS
大间隔检测

Camera解码
NaN / Inf
Joint越界
Action越界
State/Action维度
Episode完整性
Task标签
Success/Failure

P1：第二阶段完成


Jitter
Camera同步
State同步
Action同步
Action latency
Frozen Frame
Action Jump
Idle Ratio
Mean/Std/Q01/Q99

P2：规模化后引入

图像模糊
曝光检测
重复Episode检测
Trajectory聚类
Scene Diversity
Task Balance
VLM自动Subtask标注
Embedding-based数据筛选

20. 推荐工程流程

最终建议项目建立如下数据处理流水线：





21. 推荐输出文件

数据清洗工具建议为每批数据生成：

```
dataset_qc/  
├─ summary.json  
├─ episode_quality.csv  
├─ failed_episodes.txt  
├─ warning_episodes.txt  
├─ dataset_statistics.json  
└─ report.html
```

其中：


episode_quality.csv

建议字段：

```
episode_id
duration
camera_fps
state_fps
action_fps
camera_jitter
sync_error
nan_count
action_jump_count
idle_ratio
success
quality_score
status
flags
```

22. 项目阶段目标

第一阶段目标不是建立复杂的“智能数据清洗系统”，而是建立一条可靠、可重复执行的数据质量流水线：



当数据规模从几十条增长到数百、数千条后，再逐步加入：

```
自动视觉质量检测
自动数据去重
自动轨迹聚类
VLM自动标注
```

数据多样性评估
自动质量评分

最终形成可规模化运行的 VLA 数据生产与质量管理体系。